


+10% O Risco Não é Constante. Por Que Nossos Modelos Deveriam Ser?

+5 Uma jornada para modelar a natureza dinâmica da volatilidade e correlação nos mercados financeiros.



Modelos financeiros tradicionais frequentemente assumem que a volatilidade – uma medida de risco – é estável ao longo do tempo. Mas uma rápida olhada nos mercados conta uma história diferente. O risco vem em ondas. Esta apresentação explora as ferramentas econométricas que nos permitem entender, modelar e prever essa realidade.


As Três Marcas Registradas dos Retornos de Ativos Financeiros

Os retornos de ativos financeiros não se comportam aleatoriamente. Eles exibem padrões consistentes e não lineares que os modelos lineares clássicos não conseguem capturar. Entender esses 'fatos estilizados' é o primeiro passo para uma melhor modelagem de risco.



Agrupamento de Volatilidade (Volatility Clustering)

A tendência de grandes mudanças nos preços de ativos (de qualquer sinal) serem seguidas por outras grandes mudanças, e pequenas mudanças serem seguidas por outras pequenas mudanças. A volatilidade é "autocorrelacionada".



Leptocurtose (Leptokurtosis)

A distribuição dos retornos tem "caudas gordas" e um pico mais alto do que uma distribuição normal. Isso significa que eventos extremos (quedas ou picos acentuados) ocorrem com muito mais frequência do que o esperado.



Efeitos de Alavancagem (Leverage Effects)


A tendência da volatilidade aumentar mais após uma grande queda de preço do que após um aumento de preço da mesma magnitude. Más notícias impactam o risco mais do que boas notícias.

Primeiras Tentativas de Modelar a Volatilidade

Antes dos modelos avançados, os praticantes usavam métodos mais simples. Embora intuitivos, eles se mostraram inadequados para capturar a dinâmica do risco.

Volatilidade Histórica

O método mais simples: calcular a variância ou desvio padrão dos retornos sobre um período histórico fixo (por exemplo, 90 dias).




Falha Crítica

Lento para Reagir. Trata o choque de mercado de ontem e um dia calmo de três meses atrás com o mesmo peso. Ele se adapta muito lentamente a novos ambientes de volatilidade.

Média Móvel Ponderada Exponencialmente (EWMA)

Uma melhoria que atribui pesos exponencialmente decrescentes às observações passadas. Os dados mais recentes importam mais.



Falha Crítica

Não Reverte à Média. O modelo não possui um nível de volatilidade de longo prazo. Após um choque, a previsão de volatilidade permanece alta e só diminui na presença de novos menores. A volatilidade no mundo real tende a reverter à sua média.

A Revolução: Volatilidade Autoregressiva Condicional (ARCH)

“E se a volatilidade de hoje pudesse ser prevista usando o erro de previsão de ontem?”

O modelo ARCH, introduzido por Robert Engle, foi um avanço. Ele formalizou a ideia de heterocedasticidade condicional: a variância dos erros não é constante, mas depende da magnitude dos erros passados. Em outras palavras, a 'autocorrelação na volatilidade' agora podia ser modelada diretamente.

Uma linha de base, a volatilidade média de longo prazo.

A variância de hoje (nossa previsão).

$$\sigma_t^2 = \omega + \alpha_1 u_{t-1}^2$$

O 'choque' de ontem ou o erro de previsão ao quadrado. Mede as 'notícias' de ontem.

O peso que damos ao choque de ontem. Um α_1 alto significa que a volatilidade reage fortemente às notícias.

O ARCH nos deu a primeira ferramenta para modelar o agrupamento de volatilidade: um grande choque ontem (u_{t-1}^2) leva a uma previsão de alta volatilidade hoje (σ_t^2).

Diagnóstico Prático: Testando a Presença de Efeitos ARCH

Como podemos determinar estatisticamente se um modelo ARCH é apropriado para nossos dados?



Etapa 1: Estimar um Modelo de Média

Primeiro, rode um modelo linear simples (por exemplo, regressão OLS) em seus dados de retorno e salve os resíduos ($\hat{u}_t$). Esses resíduos representam a parte 'inesperada' dos retornos.

$$\hat{u}_t \rightarrow \hat{u}_t^2$$

Etapa 2: Quadrado dos Resíduos

Calcule os resíduos ao quadrado ($\hat{u}_t^2$). Como o ARCH modela a variância, focamos na magnitude dos erros, não em seu sinal.

$$\begin{aligned} y &= f(x) \\ &= + \epsilon_{t-1} \\ &- + \dots \end{aligned}$$

Etapa 3: Regredir os Resíduos ao Quadrado

Regrida os resíduos ao quadrado em seus próprios valores defasados: $\hat{u}_t^2$ em $\hat{u}_{t-1}^2, \hat{u}_{t-2}^2, \dots, \hat{u}_{t-q}^2$.



Etapa 4: Testar a Significância

A hipótese nula é que todos os coeficientes dos resíduos defasados são zero ($\gamma_1 = \dots = \gamma_q = 0$). Usamos uma estatística de teste (TR^2) que segue uma distribuição Qui-quadrado. Se rejeitarmos a nula, há evidências estatísticas de efeitos ARCH.

Se o teste for significativo, isso confirma que a volatilidade não é constante e que a volatilidade passada ajuda a prever a volatilidade futura. Um modelo da família GARCH é justificado.

Evoluindo para a Eficiência: O Modelo GARCH Generalizado

O ARCH era poderoso, mas tinha suas limitações: a necessidade de muitas defasagens (q) para capturar a persistência da volatilidade podia tornar o modelo pesado e violar as restrições de não-negatividade. O GARCH resolve isso elegantemente.

$$\sigma_t^2 = \omega + \alpha_1 u_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

$\sigma_t^2 = \omega + \alpha_1 u_{t-1}^2$

A volatilidade de base.

O Termo ARCH: A reação da volatilidade às 'notícias' de ontem.

O Termo GARCH: A persistência da volatilidade. O β_1 captura o quanto da volatilidade de ontem se transfere para hoje.

O GARCH adiciona a própria variância defasada à equação. Isso permite que um modelo GARCH(1,1) muito parcimonioso (com apenas três parâmetros) capture a mesma dinâmica de longo prazo que um modelo ARCH de ordem elevada. É mais eficiente e robusto.

Anatomia do GARCH(1,1): O Motor da Modelagem de Volatilidade

Compreendendo os três componentes fundamentais que impulsionam o modelo GARCH(1,1).



Volatilidade de Longo Prazo (Reversão à Média)

$$V_L = \frac{\omega}{1 - \alpha_1 - \beta_1}$$

O modelo possui um nível de âncora. Na ausência de choques, a volatilidade tenderá a reverter para essa média de longo prazo. Isso é crucial e reflete o comportamento do mercado no mundo real. A condição $\alpha_1 + \beta_1 < 1$ garante que essa média seja estável.



Reação a Choques (α_1)

O parâmetro α_1 mede o quão reativa a volatilidade é a novas informações. Um α_1 alto significa que o mercado reage bruscamente a surpresas, causando picos de volatilidade.

$$\sigma_t^2 = \omega + \alpha_1 u_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$




Persistência da Volatilidade (β_1)

O parâmetro β_1 mede a 'memória' da volatilidade. Um β_1 alto (próximo de 1) indica que os choques demoram muito para se dissipar, e os períodos de alta volatilidade são longos e duradouros. A soma $\alpha_1 + \beta_1$ mede a taxa geral de persistência do choque.

A Realidade Não é Simétrica: O Efeito Alavancagem


“Uma queda de -5% no mercado tem o mesmo impacto no risco que um ganho de +5%?”

Não. O GARCH padrão assume que sim, porque ele usa o erro ao quadrado (u_{t-1}^2), que ignora o sinal do choque. No entanto, empiricamente, as notícias negativas aumentam a volatilidade muito mais do que as notícias positivas da mesma magnitude.



Alavancagem Financeira

Uma queda no preço das ações aumenta o índice de endividamento (Dívida/Patrimônio Líquido) de uma empresa, tornando-a mais arriscada e suas ações mais voláteis.




Hipótese do “Prêmio de Volatilidade”

O aumento da volatilidade pode sinalizar retornos esperados mais altos (prêmio de risco), o que, por sua vez, leva a uma queda nos preços atuais das ações.

Visualizando a Assimetria: A Curva de Impacto de Notícias

A Curva de Impacto de Notícias (NIC) traça a volatilidade do próximo período (σ^2_t) em relação a vários valores do choque de hoje (u_{t-1}), mantendo as outras variáveis constantes. Ela fornece uma imagem clara de como o modelo responde a boas e más notícias.



Capturando a Assimetria: O Modelo GJR-GARCH

A Inovação: O modelo GJR (Glosten, Jagannathan e Runkle) estende o GARCH(1,1) adicionando um termo que “liga” apenas quando as notícias são negativas.

O Modelo GJR-GARCH Decomposto

$$\sigma_t^2 = \omega + \alpha_1 u_{t-1}^2 + \boxed{\gamma_1 u_{t-1}^2 * I_{t-1}} + \beta_1 \sigma_{t-1}^2$$

O Termo de Alavancagem.

I_{t-1} é uma variável indicadora que é igual a 1 se o choque de ontem (u_{t-1}) for negativo, e 0 caso contrário.
Se γ_1 for positivo e estatisticamente significativo, o efeito alavancagem está presente.

Exemplo Prático: Análise de Retornos Mensais do S&P500

Uma estimativa para o S&P500 encontrou um γ de 0.172, que era estatisticamente significativo.



Boas Notícias

Para um choque positivo ($\hat{u}_{t-1} = +0.5$), a variância condicional prevista é **1.65**.



Más Notícias

Para um choque negativo de mesma magnitude ($\hat{u}_{t-1} = -0.5$), a variância condicional prevista salta para **1.80**.

Conclusão: A má notícia resultou em uma previsão de volatilidade 9% maior, um efeito capturado pelo GJR mas perdido pelo GARCH padrão.

O Propósito Final: Previsão da Volatilidade

O principal uso dos modelos GARCH é gerar previsões da volatilidade futura. Como a volatilidade tende a reverter à média, as previsões de longo prazo convergirão para a variância incondicional do modelo, enquanto as previsões de curto prazo refletirão as condições recentes do mercado.



Aplicações Chave



Gestão de Risco

As previsões de volatilidade são um insumo direto para os cálculos de Value-at-Risk (VaR), ajudando as instituições a quantificar a perda potencial máxima de um portfólio.



Precificação de Derivativos

O modelo de Black-Scholes e outros modelos de precificação de opções requerem uma estimativa da volatilidade durante a vida da opção. As previsões GARCH fornecem estimativas dinâmicas e informadas, superiores a uma simples média histórica.




Alocação de Ativos

As estratégias de paridade de risco ajustam as alocações de portfólio com base na volatilidade prevista, visando manter um nível de risco constante.

Expandindo o Horizonte: De Ativos Únicos para Portfólios


A Limitação dos Modelos Univariados: Até agora, focamos em modelar a volatilidade de uma única série temporal. Mas em finanças, raramente nos importamos com um único ativo isoladamente. O risco de um portfólio depende crucialmente de como seus componentes se movem juntos.

Correlação Positiva Alta



Risco não diversificado.

Correlação Negativa/Baixa



Benefícios da diversificação.

Introduzindo a Correlação Condicional

Assim como a volatilidade, a correlação entre ativos não é constante. Ela tende a aumentar drasticamente durante crises de mercado – um fenômeno perigoso onde os benefícios da diversificação desaparecem quando mais precisamos deles. Modelos GARCH multivariados são projetados para capturar essa dinâmica.


Conceito Chave: Precisamos de modelos que prevejam a **matriz de covariância** inteira, não apenas as variâncias individuais.

O Desafio Multivariado: Modelando a Matriz de Covariância

O Problema

A Maldição da Dimensionalidade

Modelar diretamente todas as covariâncias se torna computacionalmente inviável muito rapidamente. Um modelo `VECH` para apenas 4 ativos requer a estimativa de 210 parâmetros! Isso leva a problemas de estimação e overfitting.



Mais Complexo / Geral

Modelos VEC/BEKK


Poderosos e gerais, mas sofrem com a proliferação de parâmetros. O modelo `BEKK` garante uma matriz de covariância positiva definida, o que é uma propriedade crucial.



Compromissos / Suposições

Modelos de Correlação Condicional Constante (CCC)

Simplifica ao assumir que as correlações são constantes, enquanto as volatilidades variam. Uma suposição forte, mas às vezes útil.



Prático / Popular

Modelos de Correlação Condicional Dinâmica (DCC)

A abordagem mais popular. É um processo de duas etapas:


- 1) Estime um modelo GARCH univariado para cada ativo.
- 2) Use os resíduos padronizados para modelar a dinâmica da matriz de correlação. Muito mais parcimonioso e intuitivo.

A Vantagem na Prática: Beta e Hedge Dinâmicos

Modelos GARCH multivariados nos permitem ir além dos parâmetros estáticos e calcular métricas de risco e relacionamento que mudam com as condições de mercado.

Betas Variáveis no Tempo

O beta do CAPM, que mede o risco sistemático de um ativo, não é constante. Usando um modelo MGARCH, podemos estimar um beta que muda a cada dia, refletindo as mudanças nas covariâncias com o mercado.



Razões de Hedge Ótimas

A razão de hedge ótima para proteger uma posição com futuros depende da covariância entre o ativo à vista e o futuro. Como essa covariância muda, a razão de hedge também deveria mudar.

Eficácia do Hedge (Redução da Variância - Out-of-Sample)		
Estratégia	Variância	Redução
Portfólio Não Protegido	0.8286	-
Hedge Ingênuo (razão=1)	0.1718	~79%
Hedge Dinâmico MGARCH Simétrico	0.1240	~85%

Ao capturar a dinâmica da volatilidade e correlação, os modelos da família GARCH fornecem ferramentas superiores para gestão de risco, alocação de ativos e estratégias de hedge, oferecendo uma vantagem mensurável sobre as abordagens estáticas.